

# 家庭电力消耗多变量时间序列预测

作者：待填写 研究领域：待填写

2026 年 6 月

**Github 链接：**待代码上传 Github 后填写。

## 1 问题介绍

随着智能家居与物联网技术的发展，家庭电力消耗监测与预测可以帮助居民理解自身用电行为、发现异常用电，并为电力公司负荷调度和供需平衡提供参考。家庭用电受到季节、日期、生活习惯和电器使用模式等多种因素影响，具有明显的时间依赖和波动性，因此适合建模为多变量时间序列预测问题。

本实验使用 UCI Machine Learning Repository 公开的 Individual Household Electric Power Consumption 数据集。该数据记录了法国一户家庭从 2006 年 12 月 16 日至 2010 年 11 月 26 日的分钟级用电情况，包括全局有功功率、无功功率、电压、电流强度以及三个分表能耗。原始数据共有 2,075,259 条记录，其中存在 25,979 条缺失记录。根据课程要求，本实验将分钟级数据聚合为天级数据，共得到 1,442 天样本。

聚合规则如下：global\_active\_power、global\_reactive\_power、sub\_metering\_1、sub\_metering\_2、sub\_metering\_3 按天求和；voltage 和 global\_intensity 按天求平均。缺失日期通过时间插值并结合前向、后向填充处理。另根据课程提示计算剩余分表能耗：

$$\begin{aligned} \text{sub\_metering\_remainder} = & \text{global\_active\_power} \times \frac{1000}{60} \\ & - (\text{sub\_metering\_1} + \text{sub\_metering\_2} + \text{sub\_metering\_3}). \end{aligned}$$

此外，为了帮助模型表达周期性，本实验加入星期和一年中日期的正余弦编码特征。

预测任务为：基于过去 90 天的多变量特征，分别预测未来 90 天和未来 365 天的每日总有功功率。两个预测长度分别训练独立模型，避免短期和长期任务之间共享模型参数。数据集按时间顺序构造滑动窗口，最后 20% 窗口作为测试集，其余窗口再划分训练集和验证集。所有划分均保持时间顺序，避免随机划分造成未来信息泄漏。

## 2 模型

### 2.1 LSTM 模型

LSTM 通过门控机制缓解普通循环神经网络在长序列上的梯度衰减问题，适合建模用电序列中的顺序依赖。本实验将过去 90 天的多变量输入送入两层 LSTM，取最后一层最后时刻的隐藏状态作为历史序列表示，再经过多层感知机一次性输出未来  $H$  天的预测结果，其中  $H \in \{90, 365\}$ 。

```
X = past 90-day multivariate sequence
h = LSTM(X).last_hidden_state
y_hat = MLP(h)
```

### 2.2 Transformer 模型

Transformer 使用自注意力机制建模不同时间位置之间的依赖关系。实验中先将每日特征线性映射到隐藏维度，再加入正弦位置编码，通过 Transformer Encoder 得到时间序列表示。最后对时间维度进行平均池化，并使用全连接层输出未来功率曲线。

```
Z = Linear(X) + PositionalEncoding
E = TransformerEncoder(Z)
h = MeanPool(E)
y_hat = MLP(h)
```

### 2.3 改进模型：CNN-Transformer

自提出模型采用 CNN-Transformer 结构。该模型首先使用一维卷积层提取相邻日期之间的局部模式，例如短期波动、周周期变化和局部趋势；随后使用 Transformer Encoder 建模较长范围的依赖关系；最后通过注意力池化聚合不同日期的信息。该结构的设计动机是：家庭用电既存在短期连续性，也存在季节性和长期趋势，卷积前端可以为 Transformer 提供更稳定的局部特征。

```
Z_local = Conv1D(X)
Z = Z_local + PositionalEncoding
E = TransformerEncoder(Z)
h = AttentionPool(E)
y_hat = MLP(h)
```


### 3 结果与分析

实验使用均方误差（MSE）和平均绝对误差（MAE）作为评价指标。每个模型在每种预测长度下使用 5 个随机种子独立训练，随机种子为 42、43、44、45、46。训练设备为 CPU，最大训练轮数为 20，使用早停策略。表中结果为 5 次实验的均值和标准差。


#### 3.1 短期预测：未来 90 天

表 1: 未来 90 天预测结果


| 模型              | MSE mean  | MSE std | MAE mean | MAE std |
|-----------------|-----------|---------|----------|---------|
| LSTM            | 157627.27 | 1762.05 | 293.33   | 2.65    |
| Transformer     | 171443.32 | 6126.89 | 316.48   | 9.24    |
| CNN-Transformer | 174413.49 | 8781.44 | 316.40   | 11.43   |



(a) LSTM, 未来 90 天



(b) Transformer, 未来 90 天



(c) CNN-Transformer, 未来 90 天


图 1: 短期预测中预测值与真实值的对比曲线, 展示 seed=42 的测试窗口结果。

短期预测中，LSTM 的 MSE 和 MAE 均最低，说明在本实验设置下，循环结构对最近 90 天历史信息的编码更稳定。Transformer 和 CNN-Transformer 的预测曲线整体更平滑，能反映总体水平，但对真实曲线中的尖峰和低谷响应不足。因此，当测试集中出现异常低用电或高峰用电时，MSE 会明显增大。CNN-Transformer 在短期任务中的表现没有超过基础模型，可能是因为训练数据量有限，而卷积和注意力模块增加了模型复杂度，导致 20 轮 CPU 训练下尚未充分收敛。


3.2 长期预测：未来 365 天

表 2: 未来 365 天预测结果


| 模型              | MSE mean  | MSE std | MAE mean | MAE std |
|-----------------|-----------|---------|----------|---------|
| Transformer     | 162738.04 | 1374.06 | 302.78   | 0.84    |
| LSTM            | 164592.31 | 2681.69 | 303.85   | 1.52    |
| CNN-Transformer | 166347.88 | 4707.92 | 306.25   | 5.01    |



(a) LSTM, 未来 365 天



(b) Transformer, 未来 365 天



(c) CNN-Transformer, 未来 365 天

图 2: 长期预测中预测值与真实值的对比曲线, 展示 seed=42 的测试窗口结果。

长期预测中, Transformer 的 MSE 和 MAE 最低, 且标准差最小, 说明自注意力机制在建模年尺度趋势方面更稳定。从曲线可以观察到, 模型能够学习到真实用电曲线中从冬季较高、夏季下降、秋冬回升的整体趋势。不过, 三种模型都对日级随机波动和极端值预测不足, 预测曲线明显比真实曲线平滑。这是多步直接预测任务中的常见现象: 模型更容易学习平均趋势, 而难以准确预测未来某一天的突发用电行为。

### 3.3 三种方法比较

综合两类任务, LSTM 更适合短期预测, Transformer 更适合长期预测。CNN-Transformer 作为改进模型具有清晰的结构动机, 但在本实验中并未取得最优性能。可能原因包括: 第一, 日级数据仅 1,442 条, 经过 90 天输入和 365 天输出窗口构造后, 可用长期训练样本较少; 第二, 模型复杂度提升后需要更长训练或更细致的超参数搜索; 第三, 用电数据中的尖峰和低谷往往由家庭行为触发, 仅凭历史功率序列难以预测。虽然改进模型性能不佳, 但其结果说明简单叠加卷积模块并不一定带来收益, 模型改进需要结合数据规模、任务长度和训练稳定性共同分析。

## 4 讨论

本实验完成了从分钟级原始数据清洗、天级聚合、滑动窗口构造到多模型训练和评估的完整流程。实验结果表明, 短期预测和长期预测的最佳模型并不相同。短期预测更依赖最近历史状态, LSTM 的门控记忆机制表现较好; 长期预测需要捕捉更长尺度的趋势, Transformer 的全局注意力机制更有优势。

本实验也存在一些限制。首先, 课程说明中提到可以融合天气数据, 但本实验为了保证主流程完整, 仅使用了原始用电变量和日期周期特征, 未加入外部气象变量。其次, 模型采用直接多步输出, 虽然训练和比较方便, 但容易产生平滑预测, 难以捕捉极端波动。再次, 受 CPU 训练时间限制, 本实验使用 20 轮训练和早停策略, 未进行大规模超参数搜索。

后续可以从三个方向改进: 一是加入天气、节假日等外部变量, 提高对季节和行为变化的解释能力; 二是尝试趋势-季节分解后再建模, 降低原始序列波动带来的学习难度; 三是为 CNN-Transformer 引入残差连接、多尺度卷积或更长训练轮数, 使其局部特征提取能力更充分发挥。

## 参考文献

1. UCI Machine Learning Repository. Individual household electric power consumption Dataset. <https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption>

2. Hochreiter, S., Schmidhuber, J. Long Short-Term Memory. *Neural Computation*, 1997.
3. Vaswani, A., Shazeer, N., Parmar, N., et al. Attention Is All You Need. *NeurIPS*, 2017.
4. 本报告文字组织和代码结构使用 ChatGPT/Codex 辅助完成，实验结果由本项目代码运行生成。